



**Analítica Descriptiva - 82.04**

**Trabajo Práctico  
Propiedades de Connecticut**

**Camilo Barbero - 63150  
Matías Díaz Cantón - 62473  
Lucía Zapata - 59504**

**Fecha de entrega: 20/06/2024**

# Índice

|                                                                                                                             |           |
|-----------------------------------------------------------------------------------------------------------------------------|-----------|
| <b>1. Introducción.....</b>                                                                                                 | <b>1</b>  |
| 1.1. Objetivos principales.....                                                                                             | 1         |
| 1.2. Posibles soluciones a las preguntas.....                                                                               | 2         |
| <b>2. Análisis exploratorio de datos.....</b>                                                                               | <b>3</b>  |
| 2.1. Selección y análisis de variables numéricas.....                                                                       | 3         |
| 2.2. Análisis de outliers.....                                                                                              | 5         |
| 2.3. Análisis de valores faltantes.....                                                                                     | 7         |
| 2.3.1. Relaciones entre variables numéricas.....                                                                            | 8         |
| 2.3.2. Imputación de numericas.....                                                                                         | 8         |
| 2.3.3. Relación entre variables categóricas y numéricas independientes.....                                                 | 9         |
| <b>3. Resultados y conclusiones.....</b>                                                                                    | <b>11</b> |
| 3.1. Análisis de Rentabilidad de Propiedades en Connecticut.....                                                            | 11        |
| 3.1.1. Análisis del Spread por Localidad.....                                                                               | 11        |
| 3.1.2. Análisis por Calidad de Propiedad y Barrio.....                                                                      | 12        |
| 3.1.3. Conclusiones.....                                                                                                    | 13        |
| 3.2. Análisis del Spread como serie temporal.....                                                                           | 14        |
| 3.2.1. Cambios en las tendencias de las transacciones inmobiliarias en la pasada década (crisis inmobiliaria del 2008)..... | 14        |
| 3.2.2. Tendencias Alcistas o Bajistas en Diferentes Regiones.....                                                           | 14        |
| 3.2.3. Mejor época para comprar y vender propiedades.....                                                                   | 15        |
| 3.2.4. Conclusiones.....                                                                                                    | 16        |

## 1. Introducción

La base de datos seleccionada para el análisis exploratorio que se realizará a lo largo de este informe es perteneciente al sitio Kaggle. El conjunto de datos provee información del mercado de los bienes raíces en Connecticut, incluyendo tendencias en el precio de las propiedades, los tipos de propiedades, y las tasas impositivas a lo largo de diferentes localidades y años.

Cada fila es cada transacción la cual incluye una propiedad, en la que se provee como columnas:

*Date*: La fecha de cuando ocurrió la transacción.

*Year*: El año de cuando ocurrió la transacción.

*Locality*: La localidad o área a la que pertenece la propiedad.

*Estimated Value*: El precio estimado de la propiedad.

*Sale Price*: El precio real de venta de la propiedad.

*Property*: El tipo de propiedad (e.g., Familiar).

*Residential*: Indica si la propiedad es residencial o no.

*Num\_rooms*: La cantidad de cuartos de la propiedad.

*Num\_bathrooms*: La cantidad de baños de la propiedad.

*Carpet Area*: Superficie alfombrada (que puede ser utilizada).

*Property Tax Rate*: La tasa impositiva aplicable a la propiedad.

*Face*: La dirección a la cual apunta la propiedad (Norte, Sur, Este u Oeste).

### 1.1. Objetivos principales

Se podría plantear como objetivos principales:

1. ¿Qué ciudad/es ofrece/n mayor rentabilidad para una propiedad?
  - Las ciudades más solicitadas para vivir se van a vender a mayor precio del estimado o su diferencia será cercana a nula?
  - ¿Es mejor una casa mala en un barrio bueno o una casa buena en un barrio malo?
2. ¿Qué variable/s afectan la rentabilidad de una propiedad? ¿Es la ciudad en la que se encuentra o los componentes propios de la propiedad como la cantidad de cuartos, baños y/o superficie alfombrada?
3. ¿Hubo cambios en las tendencias de las transacciones inmobiliarias en la pasada década? ¿Afectó la crisis inmobiliaria del 2008 a la venta de bienes raíces? ¿Hubo tendencias alcistas o bajistas en diferentes regiones?
4. ¿Cuál es la mejor época del año para comprar un inmueble?

### ***1.2. Posibles soluciones a las preguntas***

Para responder a estas interrogantes se establece como medida de éxito el spread entre el precio real y estimado de la propiedad. Esta será la principal medida y se conformará como el cociente entre el precio de venta y el precio estimado del inmueble. Para favorecer la comprensión del mismo, a la división se le restará 1 así se visualizarán los valores como negativos cuando la oferta excede a la demanda y viceversa para los valores positivos de la medida.

$$Spread = \frac{Precio\ de\ Venta}{Precio\ Estimado} - 1$$

En el caso de la primera pregunta, habría que clusterizar los precios reales y estimados por ciudad y calcular el spread promedio de las ciudades. De esta manera, la ciudad con el spread mayor a 0 máximo tendrá el mayor exceso de demanda, teniendo la mayor rentabilidad.

En el caso de la segunda pregunta, se debería hacer diferentes modelos de regresión lineal tanto simples como múltiples buscando explicar el spread a partir de diferentes combinaciones de variables de propiedades. Al realizarlos, se deberá observar el coeficiente de determinación para analizar qué modelo se ajusta mejor a los datos, y seleccionar el mismo. Este determinará la ponderación de importancia de cada variable para explicar el spread.

En el caso de la tercera pregunta, se realizaría un análisis de serie de tiempo observando tendencias año a año en el spread en las diferentes ciudades y poder concluir contrastando con los factores socio económicos de la época (como la crisis inmobiliaria del 2008) si en el contexto actual es conveniente invertir en cierta región o no.

Por último, para la cuarta pregunta se debería visualizar la variable de fecha aprovechando el hecho de que incluye el mes y el día del año. Podríamos ver históricamente en qué meses la demanda de propiedades aumenta y sacar conclusiones al respecto.

## 2. Análisis exploratorio de datos

### 2.1. Selección y análisis de variables numéricas

Para obtener una visión general y comprensiva del conjunto de datos, se realizó un análisis exploratorio de datos (EDA). Este análisis permitió no sólo entender cómo se comportan las variables por sí solas pero también las relaciones que tienen entre ellas.

Al realizar un resumen estadístico de las mismas en la *Tabla 1*, se pueden realizar ciertas observaciones. En primer lugar, la variable Year mostró un valor medio de 2130.79 y un valor máximo de 20220, indicando errores evidentes de ingreso de datos que deben ser corregidos, ya que se reportaron años irreales superiores al actual. Esto podría también hacerse notar en la poca cantidad de extremos que hay en relación a la totalidad de registros que es por encima de 10000, y cómo esto afecta la representatividad de la media que es una medida sensible a los outliers.

| Columna           | Media     | Q1        | Mediana | Q3       | Moda           | Min   | Max      | SD         | Coef_Var | Coef_Asim | Coef_Curt | Cant_NA | Uniq | % Uniq | Extremos |
|-------------------|-----------|-----------|---------|----------|----------------|-------|----------|------------|----------|-----------|-----------|---------|------|--------|----------|
| Year              | 2130.79   | 2012      | 2016    | 2020     | 2021           | 2009  | 20220    | 1438.97    | 0.68     | 12.44     | 155.79    | 58      | 29   | 0.29   | 63       |
| Estimated.Value   | 471541.33 | 131170    | 245000  | 449140   | 237930         | 0     | 26459300 | 901778.32  | 1.91     | 10.45     | 200.58    | 1286    | 7670 | 76.7   | 917      |
| Sale.Price        | 662964.51 | 160000    | 340250  | 636500   | 4e+05          | 2000  | 60893650 | 1406330.36 | 2.12     | 15.07     | 451.47    | 56      | 2639 | 26.39  | 1024     |
| num_rooms         | 3.51      | 3         | 3       | 3        | 3              | 3     | 60       | 2.54       | 0.72     | 12.09     | 185.03    | 54      | 8    | 0.08   | 1752     |
| num_bathrooms     | 2.45      | 1         | 2       | 3        | 3              | 1     | 60       | 2.23       | 0.91     | 11.52     | 213.64    | 66      | 14   | 0.14   | 117      |
| carpet_area       | 1164.19   | 960       | 1022    | 1082     | 928            | 900   | 21770    | 851.97     | 0.73     | 13.92     | 250.82    | 3455    | 811  | 8.11   | 982      |
| property_tax_rate | 1.21      | 1.0234955 | 1.03    | 1.348259 | 1.0234955      | 1     | 14.22    | 0.85       | 0.7      | 12        | 154.85    | 65      | 29   | 0.29   | 65       |
| Date              | Texto     | Texto     | Texto   | Texto    | 2021-07-02     | Texto | Texto    | Texto      | Texto    | Texto     | Texto     | 52      | 3088 | 30.88  | TEXT0    |
| Locality          | Texto     | Texto     | Texto   | Texto    | Bridgeport     | Texto | Texto    | Texto      | Texto    | Texto     | Texto     | 1297    | 8    | 0.08   | TEXT0    |
| Property          | Texto     | Texto     | Texto   | Texto    | Single Family  | Texto | Texto    | Texto      | Texto    | Texto     | Texto     | 57      | 6    | 0.06   | TEXT0    |
| Residential       | Texto     | Texto     | Texto   | Texto    | Detached House | Texto | Texto    | Texto      | Texto    | Texto     | Texto     | 58      | 5    | 0.05   | TEXT0    |
| Face              | Texto     | Texto     | Texto   | Texto    | North          | Texto | Texto    | Texto      | Texto    | Texto     | Texto     | 57      | 5    | 0.05   | TEXT0    |

Tabla 1: Resumen estadístico de las variables

En cuanto a el precio estimado y el precio de venta de las propiedades así como número de cuartos, se observa una gran cantidad de outliers. Asimismo, el precio estimado y el precio de venta ambos tienen un desvío con respecto a la media bastante alto. Esto podría deberse a la naturaleza asimétrica de estas variables al existir propiedades exorbitantemente costosas en comparación a la mayoría de las propiedades listadas. Se puede asimismo observar que el valor estimado de las propiedades tiene un mínimo de 0 lo cual no parece lógico y podría tratarse valores faltantes en la variable que habría que investigar más adelante.

Además de las medidas de resumen es importante analizar cómo se distribuyen las variables y relacionan entre sí ya que eso podría decir otra historia. Al observar el *Gráfico 1* de pares para las variables numéricas del dataset, que incluyen: el año, el precio estimado, el precio de venta, el número de habitaciones, el número de baños, área alfombrada, y la tasa de impuestos a la propiedad, se identificó una asimetría extrema hacia la derecha para todas las variables que se confirma al ver el coeficiente de curtosis de tres dígitos para todas las variables numéricas en la tabla. Esto podría deberse a la presencia de outliers, que como vimos en la tabla de resumen, existen en todas las variables. Es vital analizar si la presencia de valores extremos es debido a la naturaleza de las variables por razones como la distribución de la riqueza en la industria inmobiliaria que afecta la

construcción de las propiedades o si son casos anómalos. Dependiendo de la cantidad de outliers y la naturaleza de los mismos, se deberá decidir qué hacer con ellos al respecto, si incluirlos o imputarlos para el análisis.




Gráfico 1: Gráfico de pares de las variables cuantitativas

Por un lado, en la variable Year se observan outliers evidentes con años superiores a 2024 y otros valores de cinco dígitos, lo que no refleja una asimetría natural. Este tipo de errores sugiere la necesidad de limpiar y depurar los datos para mejorar su calidad y fiabilidad. Por otro lado, se confirma visualmente lo establecido previamente sobre el Estimated.Value, Sale.Price, num\_rooms y num\_bathrooms, donde la asimetría podría estar relacionada con la existencia de propiedades extremadamente costosas y lujosas, que elevan considerablemente los valores medios y máximos. En el caso de property\_tax\_rate, la alta variabilidad de los valores sugiere posibles errores de tipeo, ya que no es razonable encontrar grandes diferencias en las tasas impositivas dentro de un mismo estado como Connecticut.

En lo que respecta a la relación lineal entre las variables, a pesar de que pareciera no haberla, se puede ver una relación lineal moderada entre el precio estimado y el precio de venta. Esto resulta importante ya que indica que las propiedades no terminan siendo vendidas a su valor estimado, al menos en una tendencia lineal. Esto último será importante a la hora de analizar el spread de los mismos. Cabe aclarar, que la presencia de valores extremos distorsiona la correlación entre las variables lo cual podría estar haciendo que no se pueda observar una relación lineal implícita entre las mismas, particularmente en las que parece haber una relación lineal nula a simple vista.

## 2.2. Análisis de outliers

Como los outliers pueden distorsionar las estadísticas descriptivas y afectar la calidad de los modelos predictivos, se utilizó un método basado en el rango intercuartílico (IQR) para detectar outliers. Este enfoque identifica como outliers aquellos valores que se encuentran por debajo del primer cuartil menos 1.5 veces el IQR o por encima del tercer cuartil más 1.5 veces el IQR. Este criterio también fue utilizado para identificarlos en el resumen estadístico previo.




Gráfico 2: Boxplots de las variables cuantitativas

En la variable Year, se encontraron 63 outliers que parecían concentrarse alrededor del mismo valor y como se analizó previamente en el análisis exploratorio, estos se deben a claros errores de tipeo con un cero adicional al final del valor. Se decidió imputar estos outliers eliminando el cero adicional, lo que simplificó el proceso de corrección. Esto permite eliminar la asimetría extrema de la variable y se observa una distribución bastante uniforme en el Gráfico 3.




Gráfico 3: Gráfico de densidad de Year antes y después de la imputación de outliers

Para la variable `property_tax_rate`, se identificaron 65 outliers que corresponden a propiedades con más del 100% de tasa impositiva sobre la propiedad. Esto no solo resulta completamente ilógico a nivel global sino también que haya una vasta diferencia entre tasas impositivas para un mismo estado. Por lo tanto, se acordó que estos se tratan de un mal posicionamiento del punto decimal. Estos outliers se imputaron ajustando la coma decimal en lugar de utilizar métodos más complejos.





Gráfico 4: Gráfico de densidad de `property_tax_rate` antes y después de la imputación de outliers

En las variables `num_rooms` y `num_bathrooms`, a pesar de contar con bastantes outliers a través del método IQR, no se consideró apropiado el uso del mismo para la imputación. Debido a que propiedades con 4 baños o más eran consideradas como outliers, estos casos podrían deberse al hecho de ser casas de familia y no necesariamente algo a corregir. Por esta razón, como criterio de imputación se aplicó solo a los valores superiores a 10 baños o habitaciones. Esta conclusión se vio reforzada por el hecho de encontrar que todas estas propiedades presentaban casos donde se tenían 30 habitaciones pero contaban nada más con 2 baños y valían extremadamente poco al observar el valor estimado o de venta. Esto fue también válido para las propiedades con más de 10 baños.








Gráfico 5: Gráfico de densidad de num\_bathrooms y num\_rooms antes y después de la imputación de outliers

Por último, se identificaron valores "?" en la variable Property, que se transformaron en NAs para su posterior imputación al no considerarlos un tipo de propiedades válido. Asimismo, se detectaron cuatro registros con Estimated.value igual a 0, lo cual se consideró un error, como se observó en el valor mínimo de la variable en el resumen estadístico previamente. Estos valores se imputaron como NAs.

### 2.3. Análisis de valores faltantes

Luego de la limpieza de los datos extremos así como de errores en el ingreso de los datos, se buscó analizar la naturaleza de los datos faltantes para poder decidir cuál sería el método de imputación óptimo para los mismos y de tal manera disminuir lo más posible el sesgo del método elegido.


En primer lugar, fue importante descartar si los datos faltantes están distribuidos completamente al azar (MCAR) a través de un test de Little's MCAR. La hipótesis nula establece que los datos faltantes están distribuidos completamente al azar y la alternativa que no. El resultado del test ( $p\text{-valor} = 0.998$ ) sugirió que no había que rechazar la hipótesis nula, indicando que no es correcto asumir que los datos no están distribuidos completamente al azar. Esto proporcionó tranquilidad sobre la elección del método de imputación, ya que no introduciría un sesgo significativo en la distribución de los datos.

Sin embargo, para no depender de un test y elegir correctamente los métodos de imputación en vez de un único método generalizado para todas las variables, es importante analizar relaciones entre las mismas para ver si los valores son faltantes debido a las relaciones entre variables (MAR), mantener la integridad de los datos y utilizar técnicas de imputación más exactas.

### 2.3.1. Relaciones entre variables numéricas

Al analizar la relación lineal entre las variables numéricas a través del coeficiente de Pearson, para así entender si las relaciones entre ellas pueden estar afectando el mecanismo de valores faltantes, se puede observar en el *Gráfico 6* que en general se muestra una baja correlación lineal. Esto confirma lo inferido en el test de Little's acerca de ser completamente aleatorio el mecanismo.

No obstante, existen excepciones notables como `Estimated.Value` y `Sale.Price` donde la correlación es fuerte positiva indicando que al subir el valor estimado de la propiedad, sube el valor de venta y viceversa. También existe una relación lineal positiva aun mas grande superior a 0.8, entre la `num_bathrooms` y `num_bedrooms` que tiene sentido lógico ya que esto influyó en el criterio al momento de limpiar los outliers de estas dos variables, y normalmente las propiedades más grandes, con más habitaciones le acompañan mayor cantidad de baños.



*Gráfico 6: Corplot de variables numéricas*

A pesar de que las correlaciones generales son bajas, la existencia de correlaciones significativas en algunas variables sugiere que podría haber patrones en datos faltantes que merecen ser estudiados más a fondo y tomados en cuenta al momento de la imputación. El hecho de que las variables tengan relaciones específicas puede indicar que los datos no están completamente ausentes al azar (MCAR).

### 2.3.2. Imputación de numericas

En lo que respecta a los valores faltantes de `Sale.Price` y `Estimated.Value`, debido a su alta relación lineal se decidió utilizar el método de imputación múltiple con ellas por separado. A pesar de la alta correlación, se decidió por este método en vez de imputación por regresión con el fin de evitar el sesgo introducido por depender de las predicciones de un único modelo. De igual manera, se aplicó

este método para las variables num\_bathrooms y num\_rooms por extremadamente alta relación entre las mismas.

Para variables temporales como la fecha en la que se realizó la operación de compra-venta de la propiedad y su año derivado, se observó que los listings estaban en orden cronológico siguiendo un orden lineal constante. Debido a que métodos como imputación por regresión o múltiple no servirán en este caso al no tratarse de variables numéricas, tampoco serían apropiadas debido a la existencia de esta progresión cronológica que se vio anteriormente en la variable año, que al imputar sus outliers su distribución comenzó a asemejarse a una uniforme.

Por esta razón, se eligió por la interpolación lineal ya que se adapta bien a sostener una transmisión suave entre fechas y es apropiada para registros que tienen apariciones uniformes en el tiempo. Este método estimula valores faltantes asumiendo que el cambio entre dos valores conocidos sigue una línea recta. De esta manera, los valores faltantes que se encuentran en los huecos de esta línea temporal, se estiman a través de la tendencia y progresión de las fechas existentes. Por último, debido a que la variable año depende de la variable fecha simplemente se extrajo este de la otra una vez ya imputada la fecha.

### 2.3.3. Relación entre variables categóricas y numéricas independientes

Con el fin de no depender únicamente de tests de hipótesis como el test de Chi-cuadrado como criterio absoluto para estudiar las relaciones entre variables categóricas, se decidió utilizar el estadístico de V-Cramer. Este es una derivación del estadístico chi-cuadrado pero normalizado a un rango entre 0 y 1, facilitando la interpretación.

|             | Locality   | Property   | Residential | Face       |
|-------------|------------|------------|-------------|------------|
| Locality    | NA         | 0.22733113 | 0.22814665  | 0.02641787 |
| Property    | 0.22733113 | NA         | 1.00000000  | 0.01309966 |
| Residential | 0.22814665 | 1.00000000 | NA          | 0.01196709 |
| Face        | 0.02641787 | 0.01309966 | 0.01196709  | NA         |

Tabla 2: Matriz de correlación de V-Cramer entre categóricas

A pesar de que en general hay una asociación bastante baja, hay un caso excepcional donde Property y Residential están perfectamente asociadas. Esto se puede observar de manera más clara y su razón en la tabla de contingencia de los distintos niveles de ambas variables (Tabla 3), donde por cada nivel de la variable Residential existe un nivel de la variable Property y viceversa. Por esta razón, se decidió por imputar estas dos variables por separado de forma condicional una con la otra.

|               | Detached House | Duplex | Fourplex | Triplex |
|---------------|----------------|--------|----------|---------|
| Four Family   | 0              | 0      | 84       | 0       |
| Single Family | 6716           | 0      | 0        | 0       |
| Three Family  | 0              | 0      | 0        | 474     |
| Two Family    | 0              | 843    | 0        | 0       |

*Tabla 3: Tabla de contingencia entre Property y Residential*

Por último, se imputaron el resto de las variables: `carpet_area`, `Locality`, `Face`, `property_tax_rate`, así como unos 9 listings donde `Property` y `Residential` tenían valores vacíos en forma conjunta por lo cual no se podían imputar con el mecanismo anteriormente mencionado. Esto se hizo nuevamente utilizando la imputación múltiple al ser el método que menos sesgo arrastraría al análisis para estas variables en particular.

### 3. Resultados y conclusiones

#### 3.1. Análisis de Rentabilidad de Propiedades en Connecticut

##### 3.1.1. Análisis del Spread por Localidad

Para analizar la rentabilidad de las propiedades en diferentes localidades, se calculó el spread, definido como la diferencia entre el precio de venta y el valor estimado de la propiedad. El spread se calcula como:

$$Spread = \frac{Precio\ de\ Venta}{Precio\ Estimado} - 1$$

Luego, resumimos el spread por localidad, obteniendo la media, la mediana, la desviación estándar y el número de transacciones para cada localidad.

| Locality      | Mean_Spread | Median_Spread | SD_Spread | Count |
|---------------|-------------|---------------|-----------|-------|
| Greenwich     | 0.7401776   | 0.4836140     | 2.4447668 | 1224  |
| Norwalk       | 0.6536753   | 0.5002171     | 1.7523611 | 1159  |
| Stamford      | 0.5658967   | 0.4496146     | 1.3550712 | 1136  |
| West Hartford | 0.5448999   | 0.5118962     | 0.9312630 | 1239  |
| Fairfield     | 0.4956475   | 0.4005875     | 0.9626903 | 1460  |
| Waterbury     | 0.3867788   | 0.2109402     | 2.2057873 | 1817  |
| Bridgeport    | 0.3786967   | 0.3019892     | 1.0490883 | 1965  |

Tabla 4: Medidas de tendencia central y dispersión del Spread por localidad

El análisis inicial de la *Tabla 4* mostró que Greenwich tiene el spread medio más alto, lo que indica que las propiedades en esta localidad se venden en promedio a un precio significativamente mayor que su valor estimado, sugiriendo una alta rentabilidad. Sin embargo, Greenwich también muestra una alta desviación estándar en el spread, lo que indica una gran volatilidad. Esto significa que, aunque las propiedades en Greenwich pueden ofrecer alta rentabilidad, también existe un mayor riesgo de no alcanzar la rentabilidad esperada.

West Hartford, por otro lado, tiene la mediana de spread más alta. La mediana es una medida más robusta contra sesgos en los datos y sugiere que hay un 50% de probabilidad de alcanzar este spread si se decide vender una propiedad en esa localidad. Además, la proximidad entre la media y la mediana en West Hartford sugiere una menor volatilidad, haciendo de esta localidad una opción más segura para inversiones consistentes.

Al realizar un análisis más profundo, observamos que las localidades con mayor número de listados tienden a tener spreads más bajos. Esto tiene sentido, ya que un menor spread indica una menor diferencia entre el valor estimado de la propiedad y el precio de venta, lo que puede estar asociado a una mayor oferta y, por ende, a una competencia de precios más ajustada.

Por último, cabe aclarar que se realizaron pruebas exhaustivas para validar nuestras observaciones, y verificar si la diferencia entre las medias del Spread por localidad fueron significativas, y esta suposición fue afirmativa.

### 3.1.2. Análisis por Calidad de Propiedad y Barrio

Para abordar esta pregunta, clasificamos las propiedades como "buenas" o "malas" basándonos en la relación entre el número de baños y el número de habitaciones. Se considera una casa "buena" aquella que tiene al menos un baño por habitación.

Luego, calculamos el spread medio, la mediana y la desviación estándar para cada combinación de localidad y calidad de la propiedad en la *Tabla 5*. Los resultados indican que una casa mala en Greenwich (un barrio con alto spread) es más rentable en términos de spread que una casa buena en un barrio con bajo spread como Bridgeport. Esto sugiere que la rentabilidad de una propiedad está más influenciada por la localidad que por las características específicas de la propiedad.

| Locality      | Calidad_Propiedad | Mean_Spread | Median_Spread | SD_Spread | Count |
|---------------|-------------------|-------------|---------------|-----------|-------|
| Greenwich     | Buena             | 0.7688631   | 0.4745993     | 2.8439811 | 424   |
| Norwalk       | Buena             | 0.6698183   | 0.4997198     | 2.0560390 | 385   |
| West Hartford | Buena             | 0.5825734   | 0.5051174     | 1.3002938 | 441   |
| Stamford      | Buena             | 0.5125377   | 0.4264183     | 1.3320769 | 379   |
| Fairfield     | Buena             | 0.4580517   | 0.3961004     | 0.8139809 | 504   |
| Waterbury     | Buena             | 0.4418582   | 0.2133517     | 2.6428928 | 634   |
| Bridgeport    | Buena             | 0.3508740   | 0.3182085     | 0.8079702 | 626   |
| Greenwich     | Mala              | 0.7249742   | 0.4866179     | 2.2058847 | 800   |
| Norwalk       | Mala              | 0.6456455   | 0.5002961     | 1.5811465 | 774   |
| Stamford      | Mala              | 0.5926115   | 0.4584602     | 1.3665281 | 757   |
| West Hartford | Mala              | 0.5240804   | 0.5170286     | 0.6422480 | 798   |
| Fairfield     | Mala              | 0.5154678   | 0.4039631     | 1.0323578 | 956   |
| Bridgeport    | Mala              | 0.3917042   | 0.2913354     | 1.1445687 | 1339  |
| Waterbury     | Mala              | 0.3572604   | 0.2079240     | 1.9318680 | 1183  |

*Tabla 5: Medidas de tendencia central y dispersión del Spread por localidad y calidad de propiedad*

Para entender mejor qué variables afectan la rentabilidad de una propiedad, se construyó un modelo de regresión lineal optimizado. El modelo incluye variables como localidad, número de habitaciones, número de baños y superficie alfombrada para explicar la variabilidad en el spread.

|                         | Overall    |
|-------------------------|------------|
| LocalityGreenwich       | 100.000000 |
| LocalityNorwalk         | 74.081377  |
| LocalityStamford        | 48.225913  |
| `LocalityWest Hartford` | 42.158279  |
| LocalityFairfield       | 27.801860  |
| num_rooms               | 20.195258  |
| carpet_area             | 7.046375   |
| num_bathrooms           | 4.357375   |
| LocalityWaterbury       | 0.000000   |

*Tabla 6: Importancia relativa de las variables sobre el Spread a partir del modelo*

La importancia relativa de cada variable en el modelo sugiere que la localidad es la variable más influyente en la rentabilidad de una propiedad, con Greenwich mostrando una importancia relativa del 100%. Otras localidades también muestran una influencia significativa pero decreciente. La cantidad de habitaciones tiene una importancia relativa considerable (~20%), mientras que la cantidad de baños y la superficie alfombrada tienen menos impacto.

### 3.1.3. Conclusiones

En resumen, el análisis realizado revela que la rentabilidad de una propiedad está fuertemente influenciada por la localidad en la que se encuentra. Localidades solicitadas como Greenwich tienden a ofrecer mayores spreads, indicando una alta rentabilidad. Sin embargo, también presentan una mayor volatilidad, lo que implica un riesgo más elevado. Observamos que las localidades con un mayor número de listados tienden a tener spreads más bajos, lo que sugiere que una mayor oferta puede llevar a precios más competitivos y a menores diferencias entre el precio estimado y el precio de venta.


Además, la rentabilidad de una propiedad está más influenciada por la localidad que por las características específicas de la propiedad. Incluso una casa mala en un barrio bueno puede ser más rentable que una casa buena en un barrio malo. El modelo de regresión lineal indica que la localidad es la variable más importante para determinar el spread, seguida por el número de habitaciones, mientras que la cantidad de baños y la superficie alfombrada tienen un impacto menor en la rentabilidad.

Por lo tanto, para maximizar la rentabilidad de una propiedad, es crucial considerar la localidad como el factor principal, además de analizar el balance entre oferta y demanda en esa área. Este enfoque permitirá tomar decisiones más informadas y estratégicas al invertir en el mercado inmobiliario de Connecticut.

### 3.2. *Análisis del Spread como serie temporal*

#### 3.2.1. Cambios en las tendencias de las transacciones inmobiliarias en la pasada década (crisis inmobiliaria del 2008)

Durante la última década, se observaron cambios significativos en las tendencias de las transacciones inmobiliarias, particularmente influenciados por la crisis financiera de 2008. Antes de la crisis, hubo una tendencia alcista en el spread mensual promedio de las propiedades, reflejando la burbuja inmobiliaria que culminó en 2008. Durante la crisis, los precios de las propiedades se inflaron considerablemente debido a la incertidumbre económica, resultando en un spread elevado. Posteriormente, el spread disminuyó notablemente hasta 2013, indicando un período de recesión donde los precios de las propiedades cayeron y comenzaron a alinearse más estrechamente con los valores estimados, probablemente debido a una corrección del mercado y una disminución de la especulación. A partir de 2013, el spread comenzó a aumentar nuevamente, señalando una recuperación y crecimiento constante en el mercado inmobiliario. Esta tendencia general sugiere que el mercado ha estado en recuperación desde la crisis, con un incremento en los precios de las propiedades impulsado por la mejora económica y la confianza de los inversores.




*Gráfico 7: Spread Mensual Promedio a lo largo del tiempo*

#### 3.2.2. Tendencias Alcistas o Bajistas en Diferentes Regiones

El análisis desglosado por localidades reveló variaciones significativas en las tendencias del spread. Algunas regiones mostraron series temporales estacionarias, mientras que otras no. Por ejemplo, Bridgeport fue la única localidad con una serie no estacionaria desde 2009 hasta 2022. Esto puede deberse a la gentrificación y la atracción de inversiones en esa área, que han estado en aumento




en los últimos años. Otras localidades mostraron tendencias más estables y menos afectadas por las fluctuaciones del mercado post-crisis. Este comportamiento diferencial puede explicarse por varios factores, como la variación en la demanda de propiedades, las políticas locales de desarrollo urbano y las diferencias en la recuperación económica de cada región.



*Gráfico 8: Spread Mensual Promedio a lo largo del tiempo por Localidad*

### 3.2.3. Mejor época para comprar y vender propiedades

El análisis del componente estacional de la serie temporal permitió identificar los mejores meses para realizar transacciones inmobiliarias. Febrero fue identificado como el mejor mes para comprar propiedades, ya que presenta el spread más bajo, incluso negativo, lo que significa que los precios de compra son generalmente menores que los valores estimados. Este spread negativo de -11,92% sugiere que los compradores pueden obtener mejores ofertas en este mes. Por otro lado, julio fue determinado como el mejor mes para vender propiedades, con el spread más alto del año, alcanzando un 14,11% por encima del valor estimado. Esto indica que los vendedores pueden obtener precios más altos en comparación con otros meses del año, lo que maximiza sus ganancias. Estos patrones estacionales proporcionan información valiosa para planificar las transacciones inmobiliarias de manera estratégica.



*Gráfico 9: Spread Mensual Promedio en la componente estacional y residual*

### 3.2.4. Conclusiones

El análisis de series temporales de las transacciones inmobiliarias en la última década revela cambios significativos influenciados por la crisis de 2008 y la recuperación posterior. Las tendencias varían considerablemente entre diferentes regiones, reflejando factores locales como la gentrificación y la atracción de inversiones. Además, los análisis estacionales indican que febrero es el mes más favorable para comprar propiedades, mientras que julio es el mejor mes para vender. Estos hallazgos ofrecen una visión integral de las dinámicas del mercado inmobiliario y pueden servir de guía para compradores y vendedores en sus decisiones.